

- 1 Library
- 2 Proses MA(2)
- 3 Proses AR(2)
- 4 Proses ARMA(2,2)
- 5 Kesimpulan

Praktikum 4 - Proses MA(2), AR(2), dan ARMA(2,2)

Daffa Faaiz Al-Zakkii | M0401241027

2026-09-15

1 Library

```
library(TSA)
```

```
## Warning: package 'TSA' was built under R version 4.5.3
```

```
##  
## Attaching package: 'TSA'
```

```
## The following objects are masked from 'package:stats':  
##  
##   acf, arima
```

```
## The following object is masked from 'package:utils':  
##  
##   tar
```

```
library(forecast)
```

```
## Warning: package 'forecast' was built under R version 4.5.3
```

```
## Registered S3 methods overwritten by 'forecast':
##   method      from
##   fitted.Arima TSA
##   plot.Arima   TSA
```

```
library(ggplot2)
library(gridExtra)
```

```
## Warning: package 'gridExtra' was built under R version 4.5.3
```

```
library(knitr)
```

```
## Warning: package 'knitr' was built under R version 4.5.1
```

Fungsi bantu berikut dipakai berulang kali untuk membandingkan ACF/PACF teoritis vs empiris, supaya logikanya **persis sama** di ketiga bagian (MA, AR, ARMA).

```
buat_tabel_acf <- function(data_ts, lag_maks, ar = numeric(0), ma = numeric(0),
  pacf = FALSE) {

  teori <- stats::ARMAacf(ar = ar, ma = ma, lag.max = lag_maks, pacf = pacf)
  if (!pacf) teori <- teori[-1]
  teori <- as.numeric(teori)

  if (pacf) {
    empiris <- as.numeric(drop(stats::pacf(data_ts, lag.max = lag_maks, plot =
FALSE)$acf))
  } else {
    empiris <- as.numeric(drop(stats::acf(data_ts, lag.max = lag_maks, plot = F
ALSE)$acf))[-1]
  }

  data.frame(
    Lag      = 1:lag_maks,
    Teoritis = round(teori, 4),
    Empiris  = round(empiris, 4)
  )
}

lag_maks <- 5
```

2 Proses MA(2)

2.1 Membangkitkan Data

2.1.1 Cara Manual

Dibangkitkan dengan menuliskan sendiri rumus rekursif MA(2). Ditambahkan *burn-in* 50 data di awal supaya proses sudah “settle” sebelum data yang dipakai diambil (walaupun untuk MA ini efeknya kecil karena tidak ada ketergantungan ke masa lalu yang panjang, tetap dilakukan agar konsisten dengan proses AR dan ARMA nanti).

Perlu digarisbawahi bahwa `set.seed(123)` dipanggil ulang persis sebelum `rnorm()` di bagian MA(2), AR(2), maupun ARMA(2,2) Karena panjang (`N`) dan parameter `rnorm()` -nya sama, ketiga vektor *white noise* tersebut sebenarnya **identik**, bukan tiga realisasi acak yang independen. Ini bukan kesalahan yang membatalkan hasil, tujuannya supaya perbandingan karakteristik antar-proses memakai basis error yang sama/adil, tetapi perlu disadari saat membaca hasil.

```
set.seed(123)
n      <- 300
burn   <- 50
N      <- n + burn

theta1 <- 0.4
theta2 <- 0.6

e <- rnorm(N, mean = 0, sd = 1)
y_ma2 <- numeric(N)

for (t in 3:N) {
  y_ma2[t] <- e[t] + theta1 * e[t - 1] + theta2 * e[t - 2]
}

y_ma2_manual <- ts(y_ma2[(burn + 1):N])
head(y_ma2_manual, 10)
```

```
## Time Series:
## Start = 1
## End = 10
## Frequency = 1
## [1]  0.68794996  0.02275921  0.09770195  1.33432605  0.29594765  2.24732358
## [7] -1.07762715  0.87499499 -0.57155194  0.61625152
```

2.1.2 Menggunakan `arima.sim()`

```
set.seed(123)
y_ma2_sim <- stats::arima.sim(model = list(ma = c(theta1, theta2)), n = n)
head(y_ma2_sim, 10)
```


```
## Time Series:
## Start = 1
## End = 10
## Frequency = 1
## [1] 1.13035193 0.55588522 1.09271608 1.80908512 1.22451484 -0.05165576
## [7] -0.91632762 -1.47943985 0.63370530 0.58204936
```

Nilai-nilai di atas jelas beda dengan hasil manual, karena random number generator dipanggil dengan urutan yang berbeda di dalam `arima.sim()`. Yang penting bukan nilainya sama persis, tapi **karakteristik statistiknya** (rata-rata sekitar 0, ACF cut-off di lag 2) harus konsisten. Itu yang akan dicek di bagian berikutnya.


2.2 Plot Time Series

```
par(mfrow = c(2, 1))
plot(y_ma2_manual, main = "MA(2) - Manual", ylab = "Yt", xlab = "t", col = "steelblue")
abline(h = 0, lty = 2, col = "red")
plot(y_ma2_sim, main = "MA(2) - arima.sim", ylab = "Yt", xlab = "t", col = "darkorange")
abline(h = 0, lty = 2, col = "red")
```

MA(2) - Manual



MA(2) - arima.sim



```
par(mfrow = c(1, 1))
```

Interpretasi: kedua plot berfluktuasi di sekitar angka 0 dengan lebar sebaran (varians) yang relatif konstan sepanjang waktu, tidak ada tren naik/turun maupun perubahan pola musiman. Ini ciri khas data yang **stasioner dalam rata-rata dan varians**. Sesuai teori, memang MA(2) pasti stasioner berapa pun nilai θ_1 dan θ_2 -nya.

Cek invertibilitas: stasioner otomatis untuk MA berorde berapa pun, tapi *invertibilitas* (agar MA(2) bisa dituliskan ulang sebagai $AR(\infty)$ dan diidentifikasi PACF-nya) tidak otomatis dan tetap perlu dicek dari akar polinomial MA-nya. Cara paling aman dan tidak tergantung konvensi tanda adalah lewat akar polinomial:





```
roots_ma <- polyroot(c(1, theta1, theta2))
Mod(roots_ma)
```

```
## [1] 1.290994 1.290994
```

Karena modulus kedua akar > 1 , MA(2) dengan $\theta_1 = 0.4$ dan $\theta_2 = 0.6$ ini **invertible**.

2.3 ACF, PACF, dan EACF

```
par(mfrow = c(2, 2))
stats::acf(y_ma2_manual, lag.max = 20, main = "ACF MA(2) - Manual")
stats::pacf(y_ma2_manual, lag.max = 20, main = "PACF MA(2) - Manual")
stats::acf(y_ma2_sim, lag.max = 20, main = "ACF MA(2) - arima.sim")
stats::pacf(y_ma2_sim, lag.max = 20, main = "PACF MA(2) - arima.sim")
```

ACF MA(2) - Manual**PACF MA(2) - Manual****ACF MA(2) - arima.sim****PACF MA(2) - arima.sim**

```
par(mfrow = c(1, 1))
```

```
cat("EACF untuk MA(2): data manual\n")
```

```
## EACF untuk MA(2): data manual
```

```
eacf(y_ma2_manual)
```

```
## AR/MA
##   0 1 2 3 4 5 6 7 8 9 10 11 12 13
## 0 x x o x o o o o o o o o o o
## 1 x x x x o o o o o o o o o o
## 2 x x x x o x o o o o o o o o
## 3 x x x x x x o o o o o o o o
## 4 x x o x o o o o o o o o o o
## 5 x x o x x o o o o o o o o o
## 6 x x x x o o o o o o o o o o
## 7 x x x x x o o o o o o o o o
```

Interpretasi ACF/PACF/EACF:

- Pada plot **ACF**, lag 1 dan lag 2 keluar dari batas signifikansi (garis putus-putus biru), lalu lag-lag setelahnya langsung masuk ke dalam batas signifikansi (terpotong / *cut off*). Pola ini persis seperti yang diprediksi teori untuk MA(2): ACF signifikan hanya sampai lag $q = 2$.

- Pada plot **PACF**, nilainya tidak langsung terpotong, tapi meluruh (*tails off*) secara bertahap. Hal ini juga konsisten dengan sifat MA yang punya representasi $AR(\infty)$.
- Pada **EACF**, pola segitiga nol (0) biasanya mulai terlihat rapi pada baris $AR = 0$ dan kolom $MA = 2$, menunjukkan identifikasi orde (0,2) alias MA(2), cocok dengan model pembangkit.

Jadi dari ketiga alat identifikasi ini, kesimpulannya konsisten: **datanya stasioner dan identik dengan proses MA(2)**.

2.4 Scatterplot Y_t vs Lag

```
y_ma2_num <- as.numeric(y_ma2_manual)
n_ma2 <- length(y_ma2_num)

df_ma2 <- data.frame(
  Yt    = y_ma2_num,
  Yt1   = c(NA, y_ma2_num[-n_ma2]),
  Yt2   = c(NA, NA, y_ma2_num[1:(n_ma2 - 2)]),
  Yt3   = c(NA, NA, NA, y_ma2_num[1:(n_ma2 - 3)])
)
```

```
p1 <- ggplot(df_ma2, aes(Yt1, Yt)) + geom_point(alpha = 0.6, color = "steelblue") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-1 (cor=", round(cor(df_ma2$Yt, df_ma2$Yt1, use = "complete.obs"), 3), ")"))

p2 <- ggplot(df_ma2, aes(Yt2, Yt)) + geom_point(alpha = 0.6, color = "darkgreen") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-2 (cor=", round(cor(df_ma2$Yt, df_ma2$Yt2, use = "complete.obs"), 3), ")"))

p3 <- ggplot(df_ma2, aes(Yt3, Yt)) + geom_point(alpha = 0.6, color = "purple") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-3 (cor=", round(cor(df_ma2$Yt, df_ma2$Yt3, use = "complete.obs"), 3), ")"))

grid.arrange(p1, p2, p3, ncol = 1)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 1 row containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 1 row containing missing values or values outside the scale range
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 2 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```


```
## Warning: Removed 2 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```


```
## Warning: Removed 3 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 3 rows containing missing values or values outside the scale range
## (`geom_point()`).
```


Yt vs Yt-1 (cor=0.398)



Yt vs Yt-2 (cor=0.293)



Yt vs Yt-3 (cor=-0.112)



Interpretasi: titik-titik pada Y_t vs Y_{t-1} dan Y_t vs Y_{t-2} menunjukkan pola linear yang cukup terlihat (garis merah tidak datar), sedangkan pada Y_t vs Y_{t-3} titik-titiknya menyebar acak tanpa pola (garis merah nyaris datar). Ini sejalan dengan teori: korelasi antara Y_t dan Y_{t-k} untuk MA(2) hanya ada sampai $k = 2$, sedangkan $k = 3$ ke atas seharusnya sekitar nol.

2.5 Autokorelasi: Empiris vs Teoritis

```
rho1_teoris <- (theta1 + theta1*theta2) / (1 + theta1^2 + theta2^2)
rho2_teoris <- theta2 / (1 + theta1^2 + theta2^2)

tabel_ma2 <- buat_tabel_acf(y_ma2_manual, lag_maks, ma = c(theta1, theta2))
kable(tabel_ma2, caption = "Perbandingan ACF Teoritis vs Empiris - MA(2)")
```

Perbandingan ACF Teoritis vs Empiris - MA(2)

Lag	Teoritis	Empiris
1	0.4211	0.3978
2	0.3947	0.2923
3	0.0000	-0.1115
4	0.0000	-0.1891
5	0.0000	-0.0966

Secara manual (rumus), $\rho_1 = 0.4211$ dan $\rho_2 = 0.3947$, sedangkan lag 3 dan seterusnya teoritis persis 0. Dari tabel di atas terlihat nilai empiris (dari 300 data bangkitan) mendekati nilai teoritisnya, meskipun tidak identik. Ini wajar karena ini hanya satu realisasi/sampel dari proses stokastiknya, bukan populasi. Semakin banyak data dibangkitkan, nilai empiris akan makin mendekati nilai teoritis (hukum bilangan besar).

3 Proses AR(2)

3.1 Membangkitkan Data

3.1.1 Cara Manual

```
set.seed(123)
phi1 <- 0.5
phi2 <- 0.2

e2 <- rnorm(N, mean = 0, sd = 1)
y_ar2 <- numeric(N)

for (t in 3:N) {
  y_ar2[t] <- phi1 * y_ar2[t - 1] + phi2 * y_ar2[t - 2] + e2[t]
}

y_ar2_manual <- ts(y_ar2[(burn + 1):N])
head(y_ar2_manual, 10)
```

```
## Time Series:
## Start = 1
## End = 10
## Frequency = 1
## [1] 0.3696158 0.1648268 0.1134661 1.4583007 0.5260726 2.0711670
## [7] -0.4079548 0.7948698 0.4396982 0.5947646
```

3.1.2 Menggunakan arima.sim()


```
set.seed(123)
y_ar2_sim <- stats::arima.sim(model = list(ar = c(phi1, phi2)), n = n)
head(y_ar2_sim, 10)
```

```
## Time Series:
## Start = 1
## End = 10
## Frequency = 1
## [1] -2.9518714 -1.0047928 -0.9393975 -1.8087943 0.1615383 0.1454745
## [7] -0.1900266 0.8292073 1.2547318 1.6147884
```


3.2 Plot Time Series

```
par(mfrow = c(2, 1))
plot(y_ar2_manual, main = "AR(2) - Manual", ylab = "Yt", xlab = "t", col = "steelblue")
abline(h = 0, lty = 2, col = "red")
plot(y_ar2_sim, main = "AR(2) - arima.sim", ylab = "Yt", xlab = "t", col = "darkorange")
abline(h = 0, lty = 2, col = "red")
```

AR(2) - Manual



AR(2) - arima.sim







```
par(mfrow = c(1, 1))
```

Interpretasi: sama seperti MA(2), plot berayun di sekitar nol dengan varians yang relatif stabil. Bedanya, pola pergerakan AR(2) terlihat sedikit lebih “halus”/smooth dibanding MA(2), karena nilai sekarang dipengaruhi nilai-nilai sebelumnya (ada ketergantungan/*persistence*), bukan cuma error acak.

3.3 ACF, PACF, dan EACF

```
par(mfrow = c(2, 2))
stats::acf(y_ar2_manual, lag.max = 20, main = "ACF AR(2) - Manual")
stats::pacf(y_ar2_manual, lag.max = 20, main = "PACF AR(2) - Manual")
stats::acf(y_ar2_sim, lag.max = 20, main = "ACF AR(2) - arima.sim")
stats::pacf(y_ar2_sim, lag.max = 20, main = "PACF AR(2) - arima.sim")
```

ACF AR(2) - Manual**PACF AR(2) - Manual****ACF AR(2) - arima.sim****PACF AR(2) - arima.sim**

```
par(mfrow = c(1, 1))
```

```
cat("EACF untuk AR(2) - data manual\n")
```

```
## EACF untuk AR(2) - data manual
```

```
eacf(y_ar2_manual)
```

```
## AR/MA
##   0 1 2 3 4 5 6 7 8 9 10 11 12 13
## 0 x x x o o o o o o o o o o o
## 1 x o o o o o o o o o o o o o
## 2 x x o o o o o o o o o o o
## 3 x x o o o x o o o o o o o
## 4 x o o o o x o o o o o o o
## 5 x x o x o o o o o o o o o
## 6 x x o x x o o o o o o o o
## 7 x x o x x o o o o o o o o
```

Interpretasi ACF/PACF/EACF:

- **ACF** meluruh perlahan (tails off), tidak langsung terpotong di lag tertentu, mengonfirmasi adanya proses AR.
- **PACF** signifikan jelas di lag 1. Di lag 2, nilai empirisnya (≈ 0.113 , lihat tabel PACF di bagian Autokorelasi) berada nyaris tepat di garis signifikansi $\pm 1.96/\sqrt{300} \approx 0.113$, jadi

secara visual agak samar. Ini bukan berarti orde AR = 2 salah, secara *teoritis* PACF lag 2 untuk proses ini memang $\phi_2 = 0.2$ (tidak nol), hanya saja pada satu realisasi sampel (n=300) nilainya kebetulan lemah karena variasi sampling, jadi “cut off lag 2” di sini lebih tepat disebut didukung teori, bukan terlihat setegas contoh buku teks.

- **EACF** perlu dicermati lebih teliti: pada tabel di atas, sel (AR = 2, MA = 0) itu sendiri masih bertanda “x”, bukan “o”. Pola segitiga nol yang benar-benar konsisten (semua “o” ke kanan dan ke bawah) baru mulai rapi sekitar kolom MA = 2, bukan MA = 0. Ini gejala umum EACF dari data simulasi ukuran terbatas (n=300) yang jarang membentuk segitiga sempurna seperti pada ilustrasi buku teks. Kesimpulan identifikasi tetap mengarah ke proses AR berorde rendah (konsisten dengan AR(2) yang sebenarnya), tapi klaim “vertex tepat di AR=2, MA=0” dari tabel ini saja kurang akurat dan sebaiknya dikombinasikan dengan hasil ACF/PACF di atas, bukan berdiri sendiri.

3.4 Scatterplot Y_t vs Lag

```
y_ar2_num <- as.numeric(y_ar2_manual)
n_ar2 <- length(y_ar2_num)

df_ar2 <- data.frame(
  Yt    = y_ar2_num,
  Yt1   = c(NA, y_ar2_num[-n_ar2]),
  Yt2   = c(NA, NA, y_ar2_num[1:(n_ar2 - 2)]),
  Yt3   = c(NA, NA, NA, y_ar2_num[1:(n_ar2 - 3)])
)
```

```
p1 <- ggplot(df_ar2, aes(Yt1, Yt)) + geom_point(alpha = 0.6, color = "steelblue") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-1 (cor=", round(cor(df_ar2$Yt, df_ar2$Yt1, use = "complete.obs"), 3), ")"))
```

```
p2 <- ggplot(df_ar2, aes(Yt2, Yt)) + geom_point(alpha = 0.6, color = "darkgreen") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-2 (cor=", round(cor(df_ar2$Yt, df_ar2$Yt2, use = "complete.obs"), 3), ")"))
```

```
p3 <- ggplot(df_ar2, aes(Yt3, Yt)) + geom_point(alpha = 0.6, color = "purple") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-3 (cor=", round(cor(df_ar2$Yt, df_ar2$Yt3, use = "complete.obs"), 3), ")"))
```

```
grid.arrange(p1, p2, p3, ncol = 1)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 1 row containing non-finite outside the scale range  
## (`stat_smooth()`).
```

```
## Warning: Removed 1 row containing missing values or values outside the scale  
range  
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 2 rows containing non-finite outside the scale range  
## (`stat_smooth()`).
```


```
## Warning: Removed 2 rows containing missing values or values outside the scal  
e range  
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```


```
## Warning: Removed 3 rows containing non-finite outside the scale range  
## (`stat_smooth()`).
```

```
## Warning: Removed 3 rows containing missing values or values outside the scal  
e range  
## (`geom_point()`).
```


Yt vs Yt-1 (cor=0.547)



Yt vs Yt-2 (cor=0.38)



Yt vs Yt-3 (cor=0.226)



Interpretasi: berbeda dengan MA(2), di sini pola linear masih cukup terlihat bahkan sampai Y_t vs Y_{t-3} , walau kemiringannya makin landai (korelasi makin kecil seiring lag makin jauh). Ini karena pada AR, ketergantungan antar waktu bersifat “menular” terus ke lag-lag berikutnya (meluruh, tidak putus tiba-tiba), berbeda dengan MA yang ketergantungannya benar-benar berhenti setelah lag q .

Verifikasi numerik syarat stasioner:

```
phi1 + phi2      # harus < 1
```

```
## [1] 0.7
```

```
phi2 - phi1      # harus < 1
```

```
## [1] -0.3
```

```
abs(phi2)        # harus < 1
```

```
## [1] 0.2
```

```
roots_ar <- polyroot(c(1, -phi1, -phi2))
Mod(roots_ar)
```

```
## [1] 1.311738 3.811738
```

Ketiga syarat segitiga kestasioneran AR(2) terpenuhi, dan kedua akar polinomial karakteristiknya berada di luar lingkaran satuan. Jadi proses AR(2) ini terbukti **stasioner secara numerik**, bukan sekadar dugaan dari plot.

3.5 Autokorelasi: Empiris vs Teoritis

```
rho1_ar_teoris <- phi1 / (1 - phi2)
rho2_ar_teoris <- phi1*rho1_ar_teoris + phi2*1
rho3_ar_teoris <- phi1*rho2_ar_teoris + phi2*rho1_ar_teoris

tabel_ar2 <- buat_tabel_acf(y_ar2_manual, lag_maks, ar = c(phi1, phi2))
kable(tabel_ar2, caption = "Perbandingan ACF Teoritis vs Empiris - AR(2)")
```

Perbandingan ACF Teoritis vs Empiris - AR(2)

Lag	Teoritis	Empiris
1	0.6250	0.5461
2	0.5125	0.3777
3	0.3812	0.2248
4	0.2931	0.1007
5	0.2228	0.0833

Dari rumus Yule-Walker: $\rho_1 = 0.625$, $\rho_2 = 0.5125$, $\rho_3 = 0.3812$, dan seterusnya meluruh menuju 0 tapi tidak pernah benar-benar putus. Nilai empiris pada tabel di atas cukup dekat dengan nilai teoritisnya, meskipun selisihnya sedikit lebih besar dibanding kasus MA(2). Ini masuk akal karena pada AR, efek estimasi (dari data yang terbatas dan adanya feedback antar-lag) terakumulasi sepanjang waktu.

Selain ACF, bisa juga dicek PACF secara teoritis:

```
tabel_pacf_ar2 <- buat_tabel_acf(y_ar2_manual, lag_maks, ar = c(phi1, phi2), pacf = TRUE)
kable(tabel_pacf_ar2, caption = "Perbandingan PACF Teoritis vs Empiris - AR(2)")
```

Perbandingan PACF Teoritis vs Empiris - AR(2)

Lag	Teoritis	Empiris
1	0.625	0.5461
2	0.200	0.1132

Lag	Teoritis	Empiris
3	0.000	-0.0287
4	0.000	-0.0596
5	0.000	0.0530

Terlihat PACF teoritis sudah 0 (mendekati 0) mulai lag 3, sesuai definisi bahwa AR(2) hanya punya 2 PACF signifikan.

4 Proses ARMA(2,2)

4.1 Membangkitkan Data

4.1.1 Cara Manual

```
set.seed(123)
e3 <- rnorm(N, mean = 0, sd = 1)
y_arma22 <- numeric(N)

for (t in 3:N) {
  y_arma22[t] <- phi1 * y_arma22[t - 1] + phi2 * y_arma22[t - 2] +
    e3[t] + theta1 * e3[t - 1] + theta2 * e3[t - 2]
}

y_arma22_manual <- ts(y_arma22[(burn + 1):N])
head(y_arma22_manual, 10)
```

```
## Time Series:
## Start = 1
## End = 10
## Frequency = 1
## [1] 0.6713957 0.3383694 0.4011658 1.6025828 1.1774722 3.1565762 0.7361554
## [8] 1.8743879 0.5128731 1.2475657
```

4.1.2 Menggunakan arima.sim()


```
set.seed(123)
y_arma22_sim <- stats::arima.sim(model = list(ar = c(phi1, phi2), ma = c(theta1, theta2)), n = n)
head(y_arma22_sim, 10)
```

```
## Time Series:
## Start = 1
## End = 10
## Frequency = 1
## [1] -3.11187150 -2.78699743 -1.12528900 -0.87493596 -0.03472262  0.84062710
## [7]  1.47250989  2.61429024  3.14579988  3.41808039
```


4.2 Plot Time Series

```
par(mfrow = c(2, 1))
plot(y_arma22_manual, main = "ARMA(2,2) - Manual", ylab = "Yt", xlab = "t", col = "steelblue")
abline(h = 0, lty = 2, col = "red")
plot(y_arma22_sim, main = "ARMA(2,2) - arima.sim", ylab = "Yt", xlab = "t", col = "darkorange")
abline(h = 0, lty = 2, col = "red")
```

ARMA(2,2) - Manual



ARMA(2,2) - arima.sim



```
par(mfrow = c(1, 1))
```

Interpretasi: seperti dua proses sebelumnya, data berfluktuasi stabil di sekitar 0 tanpa tren maupun perubahan varians yang mencolok sepanjang waktu observasi → **stasioner**, sesuai hasil pengecekan syarat kestasioneran bagian AR di atas.

Syarat ARMA(2,2): untuk proses campuran, dua syarat harus dicek terpisah: kestasioneran ditentukan hanya oleh bagian AR-nya, dan invertibilitas ditentukan hanya oleh bagian MA-nya. Karena ϕ_1, ϕ_2 dan θ_1, θ_2 di sini persis sama dengan yang sudah diverifikasi sebelumnya, kedua syarat tersebut otomatis ikut terpenuhi:

```
Mod(polyroot(c(1, -phi1, -phi2)))
```

```
## [1] 1.311738 3.811738
```

```
Mod(polyroot(c(1, theta1, theta2)))
```


```
## [1] 1.290994 1.290994
```

Karena seluruh akar dari kedua polinomial berada di luar lingkaran satuan, ARMA(2,2) dengan parameter ini terbukti **stasioner sekaligus invertible**.


4.3 ACF, PACF, dan EACF

```
par(mfrow = c(2, 2))
stats::acf(y_arma22_manual, lag.max = 20, main = "ACF ARMA(2,2) - Manual")
stats::pacf(y_arma22_manual, lag.max = 20, main = "PACF ARMA(2,2) - Manual")
stats::acf(y_arma22_sim, lag.max = 20, main = "ACF ARMA(2,2) - arima.sim")
stats::pacf(y_arma22_sim, lag.max = 20, main = "PACF ARMA(2,2) - arima.sim")
```


ACF ARMA(2,2) - Manual




PACF ARMA(2,2) - Manual



ACF ARMA(2,2) - arima.sim



PACF ARMA(2,2) - arima.sim



```
par(mfrow = c(1, 1))
```

```
cat("EACF untuk ARMA(2,2) - data manual\n")
```

```
## EACF untuk ARMA(2,2) - data manual
```

```
eacf(y_arma22_manual)
```

```
## AR/MA
##   0 1 2 3 4 5 6 7 8 9 10 11 12 13
## 0 x x x x x o o o o o o o o o
## 1 o x o o o x o o o o o o o o
## 2 o x o o o x o o o o o o o o
## 3 x x o x o x o o o o o o o o
## 4 x x o x o x o o o o o o o o
## 5 x x x x o o o o o o o o o o
## 6 o x o x o o o o o o o o o o
## 7 o x o x o o o o o o o o o o
```

Interpretasi ACF/PACF/EACF:

- **ACF** maupun **PACF** sama-sama meluruh (tails off) secara bertahap, tidak ada satu pun yang cut off tegas di lag tertentu. Ini memang ciri khas proses campuran ARMA, dua plot ini jadi kurang tegas untuk menentukan orde p dan q secara terpisah.

- Karena itu, **EACF** jadi alat yang lebih diandalkan, pola segitiga nol (bagian yang didominasi simbol "0") mulai konsisten rapi kira-kira pada baris AR=2 dan kolom MA=2, yang cocok dengan model pembangkit ARMA(2,2).

4.4 Scatterplot Y_t vs Lag

```
y_arma22_num <- as.numeric(y_arma22_manual)
n_arma22 <- length(y_arma22_num)

df_arma22 <- data.frame(
  Yt = y_arma22_num,
  Yt1 = c(NA, y_arma22_num[-n_arma22]),
  Yt2 = c(NA, NA, y_arma22_num[1:(n_arma22 - 2)]),
  Yt3 = c(NA, NA, NA, y_arma22_num[1:(n_arma22 - 3)])
)
```

```
p1 <- ggplot(df_arma22, aes(Yt1, Yt)) + geom_point(alpha = 0.6, color = "steelblue") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-1 (cor=", round(cor(df_arma22$Yt, df_arma22$Yt1, use="complete.obs"),3),""))

p2 <- ggplot(df_arma22, aes(Yt2, Yt)) + geom_point(alpha = 0.6, color = "darkgreen") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-2 (cor=", round(cor(df_arma22$Yt, df_arma22$Yt2, use="complete.obs"),3),""))

p3 <- ggplot(df_arma22, aes(Yt3, Yt)) + geom_point(alpha = 0.6, color = "purple") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(title = paste0("Yt vs Yt-3 (cor=", round(cor(df_arma22$Yt, df_arma22$Yt3, use="complete.obs"),3),""))

grid.arrange(p1, p2, p3, ncol = 1)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 1 row containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 1 row containing missing values or values outside the scale range
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```


```
## Warning: Removed 2 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 2 rows containing missing values or values outside the scale range
## (`geom_point()`).
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: Removed 3 rows containing non-finite outside the scale range
## (`stat_smooth()`).
```

```
## Warning: Removed 3 rows containing missing values or values outside the scale range
## (`geom_point()`).
```



Interpretasi: pola hubungannya berada di antara MA(2) dan AR(2), masih ada kemiringan yang terlihat sampai Y_t vs Y_{t-3} (mirip AR karena efek bagian AR yang meluruh terus), tapi kekuatannya bisa jadi sedikit berbeda dari AR(2) murni karena ada tambahan pengaruh komponen MA yang memperkuat/melemahkan korelasi di lag-lag awal.

4.5 Autokorelasi: Empiris vs Teoritis

Untuk ARMA campuran, rumus ACF teoritisnya cukup rumit untuk diturunkan manual, sehingga dihitung dengan fungsi `ARMAacf()` di R (fungsi ini tetap menghitung nilai analitik/teoritis, bukan simulasi berulang):

```
tabel_arma22 <- buat_tabel_acf(y_arma22_manual, lag_maks, ar = c(phi1, phi2), m
a = c(theta1, theta2))
kable(tabel_arma22, caption = "Perbandingan ACF Teoritis vs Empiris - ARMA(2,
2)")
```

Perbandingan ACF Teoritis vs Empiris - ARMA(2,2)

Lag	Teoritis	Empiris
1	0.8592	0.8115
2	0.7492	0.6437
3	0.5464	0.3813
4	0.4231	0.2216
5	0.3208	0.1456

Terlihat pola ACF teoritis meluruh secara bertahap menuju 0 (tidak terputus tegas seperti MA murni), dan nilai empirisnya cukup mendekati, walau ada sedikit deviasi di lag-lag akhir. Ini hal wajar karena estimasi dari sampel terbatas (300 data) dan efek gabungan AR+MA yang saling berinteraksi membuat variasi sampling sedikit lebih besar.

5 Kesimpulan

Proses	Syarat Stasioner Terpenuhi?	Pola ACF	Pola PACF	Identifikasi via EACF
MA(2)	Selalu stasioner	Cut off lag 2	Tails off	AR=0, MA=2
AR(2)	Ya ($\phi_1 + \phi_2 < 1$, dll)	Tails off	Cut off lag 2	AR=2, MA=0
ARMA(2,2)	Ya (mengikuti bagian AR)	Tails off	Tails off	AR=2, MA=2

Dari ketiga proses yang dibangkitkan, semuanya terbukti **stasioner** baik secara visual (plot time series berfluktuasi stabil di sekitar rata-rata konstan) maupun secara teoritis (syarat kestasioneran terpenuhi untuk semua kasus). Ciri khas masing-masing proses juga berhasil dikonfirmasi lewat kombinasi ACF, PACF, dan EACF:

- MA(2) → ACF cut off, PACF tails off
- AR(2) → ACF tails off, PACF cut off
- ARMA(2,2) → keduanya tails off, sehingga EACF jadi alat identifikasi yang paling diandalkan

Nilai autokorelasi hasil hitungan dari data bangkitan (empiris) secara umum konsisten mendekati nilai teoritisnya, dengan sedikit deviasi yang wajar karena sifat sampling dari data yang dibangkitkan secara acak (bukan populasi penuh).